

Atividade Prática: Web Scraping e Regressão Linear para Previsão de Preços de Imóveis

1. Contexto e Motivação

A valorização de imóveis é influenciada por diversos fatores: área, localização, número de quartos, vagas de garagem, andar, entre outros. Nesta atividade, você atuará como engenheiro de dados e deverá **coletar dados reais** de um site de imóveis, **estruturá-los** e **construir um modelo de regressão linear** capaz de estimar o preço de venda (ou aluguel) de um imóvel a partir de suas características.

1. Objetivos de Aprendizagem

Ao final da atividade, o estudante será capaz de:

1. Realizar **web scraping** com a biblioteca `BeautifulSoup` e `requests` (ou `Selenium/Playwright` para sites dinâmicos).
2. Estruturar os dados coletados em um **DataFrame pandas**.
3. Realizar **análise exploratória (EDA)**: estatísticas descritivas, distribuições, correlações.
4. **Limpar e tratar** dados (valores ausentes, outliers, conversão de tipos).
5. Ajustar um modelo de **regressão linear múltipla** com `scikit-learn`.
6. Avaliar o modelo com métricas (R^2 , RMSE, MAE) e interpretar coeficientes.
7. Refletir sobre **limitações éticas e técnicas** do scraping.

2. Roteiro da Atividade

Etapa 1 – Coleta de Dados (Web Scraping)

Sites sugeridos (escolha 1):

- <https://www.vivareal.com.br> — grande volume, HTML dinâmico (requer Selenium/Playwright).
- <https://www.zapimoveis.com.br> — similar ao VivaReal.
- <https://www.imovelweb.com.br>
- <https://www.quintoandar.com.br> — aluguel, ótima estrutura.

Requisitos mínimos da coleta:

- **Mínimo de 100 imóveis** (ideal: 300+).
- Filtre por uma **cidade específica** (ex.: São Paulo, Belo Horizonte) para reduzir variabilidade geográfica.
- Colete as seguintes variáveis:
 - `preco (R$)`
 - `area_m2`

- o quartos
- o banheiros
- o vagas
- o bairro
- o tipo (apartamento, casa, etc.)

Etapa 2 – Limpeza e Tratamento

Tarefas obrigatórias:

1. Converter "R\$ 1.200.000" → 1200000.0.
2. Converter "75 m²" → 75.0.
3. Tratar valores ausentes (dropna ou imputação).
4. Remover **outliers** evidentes (ex.: imóveis com preço > 3× IQR).
5. Criar a variável `preco_m2 = preco / area_m2` para análise.

Etapa 3 – Análise Exploratória (EDA)

Produza **no mínimo**:

- Histograma de `preco` e `preco_m2`.
- Matriz de correlação (`sns.heatmap`).
- Scatter `area_m2` × `preco` com reta de tendência.
- Boxplot de `preco` por `bairro` (top 10 bairros).

Pergunta para reflexão: quais variáveis parecem mais correlacionadas com o preço? A relação é linear?

Etapa 4 – Modelagem com Regressão Linear

Variáveis preditoras sugeridas: `area_m2`, `quartos`, `banheiros`, `vagas`.

- Adicionar `bairro` via **One-Hot Encoding**.
- Comparar com **Ridge/Lasso**.
- Testar transformação logarítmica em `preco`.
- Verificar **multicolinearidade** (VIF).

Etapa 5 – Interpretação e Relatório

Produza um **relatório técnico (2–4 páginas)** contendo:

1. Descrição da fonte de dados e método de coleta.
2. Estatísticas descritivas da amostra.
3. Gráficos da EDA.
4. Especificação do modelo e métricas.
5. **Interpretação dos coeficientes** (ex.: "cada m² adicional eleva o preço em R\$ X").
6. Limitações: amostra pequena, viés de anúncios, seleção geográfica.
7. Considerações éticas sobre scraping.